

陪伴类 AI 智能体项目分模块预算与团队执行方案

版本：V1.0
用途：技术可行性调研后的预算拆解、团队配置、阶段执行与投资评估
口径：人民币 RMB，按中国大陆中小型研发团队项目制估算
说明：本文预算为“研发落地预算模型”，不是外包固定报价。实际费用会受城市、人员资历、是否全职、云模型调用量、美术资产质量、硬件数量、并发规模影响。

1. 项目目标复述

本项目目标不是普通聊天机器人，而是一个具备以下能力的长期记忆型虚拟陪伴智能体 / 数字生命系统：

- 1. 稳定人格与 OOC 边界；
- 2. 长期记忆、短期记忆、用户画像、关系状态；
- 3. 多模型路由、本地模型实验、云端模型调用；
- 4. 语音输入、语音输出、情绪语音；
- 5. Unity / Web / 移动端 / PC 端角色表现；
- 6. 表情、口型、动作、情绪状态同步；
- 7. 工具调用、文件/代码/表格能力、安全沙箱；
- 8. 跨设备注册、心跳、任务下发与状态同步；
- 9. 监控、日志、链路追踪、数据备份、权限与审计；
- 10. 后期可扩展动作生成、实时数字人、知识图谱、LoRA 人格实验。

因此，本项目应按“平台型 AI 产品 + 角色表现系统 + 多端协同系统”评估预算，而不是按一个单一 App 或单一 Agent Demo 评估。

2. 预算测算基本假设

2.1 人月成本假设

本文采用“综合人月成本”估算，包括：

- 税前薪资或外包人力成本；
- 社保、公积金、奖金、设备、办公、管理摊销；
- 招聘、沟通、项目管理、测试返工成本；
- 10%-20% 研发不确定性缓冲。

角色	普通/中级人月	高级/核心人月	备注
产品负责人 / 项目经理	2.5-4 万	4-6 万	负责版本范围、验收、协调
技术负责人 / 架构师	5-7 万	7-10 万	核心岗位，不建议省
AI 后端 / Agent 工程师	3.5-5.5 万	5.5-8 万	LangGraph、LiteLLM、工具调用
记忆系统 / 数据工程师	4-6 万	6-9 万	长期记忆、pgvector、数据模型
Unity / 客户端工程师	3-5 万	5-7.5 万	角色表现、WebSocket、动作
语音 / 多模态工程师	4-6.5 万	6.5-10 万	ASR、TTS、语音延迟、动作预研
前端 / 管理后台工程师	2.8-4.5 万	4.5-6.5 万	管理台、调试台、设备面板
DevOps / 安全工程师	3.5-5.5 万	5.5-8 万	部署、监控、权限、安全
QA / 测试工程师	1.8-3 万	3-4.5 万	功能、回归、人格/OOC 测试

角色	普通/中级人月	高级/核心人月	备注
角色体验策划 / 编剧	2.5-4 万	4-6 万	人设、关系、情绪、 OOC 规则
技术美术 / 动画	3-5 万	5-8 万	表情、动作、口型、 Unity 表现
算法 / 模型工程师	5-8 万	8-12 万	本地模型、LoRA、动 作生成预研

2.2 非人力成本假设

项目	MVP 阶段	产品化阶段	完整平台阶段	说明
云服务器 / 数据库 / 存储	0.5-2 万/月	2-8 万/月	8-30 万/月	取决于并发、音视频存储、模型是否本地化
LLM API 调用	0.5-5 万/月	5-30 万/月	30 万 +/月	取决于用户量、上下文长度、模型等级
ASR / TTS API	0.3-3 万/月	3-20 万/月	20 万 +/月	语音产品会持续产生费用
美术资产 / 角色模型	5-30 万	30-150 万	150 万 +	取决于角色品质、动作、表情、服装
测试设备	3-15 万	15-50 万	50 万 +	手机、PC、麦克风、摄像头、VR/MR 设备等
第三方 SaaS / 工具	0.2-2 万/月	2-10 万/月	10 万 +/月	LangSmith、监控、协作、素材、API 等
安全与合规	2-10 万	10-50 万	50 万 +	隐私、权限、审计、渗透测试

3. 分模块预算总览

以下预算按“完整实现文档目标”拆分。每个模块分为三档：

- **基础档**：能跑通核心能力，适合 MVP；
- **产品档**：可用于 Beta 或小规模上线；
- **增强档**：更接近商业化完整版本。

模块	基础档预算	产品档预算	增强档预算	自研程度	优先级
1. 产品设计与项目管理	20-40 万	60-120 万	150-250 万	中	P0
2. 技术架构与基础工程	35-70 万	100-180 万	250-400 万	中	P0
3. AI 对话编排与模型网关	50-100 万	120-250 万	300-500 万	中高	P0
4. 人格系统 / OOC / 关系状态	40-90 万	120-260 万	300-600 万	高	P0
5. 长期记忆系统	60-130 万	180-380 万	450-800 万	高	P0

模块	基础档预算	产品档预算	增强档预算	自研程度	优先级
6. 语音交互系统	40-90 万	120-280 万	350-700 万	中高	P1
7. Unity 角色表现系统	60-150 万	200-500 万	600-1200 万	高	P1
8. Web 管理后台 / 调试台	30-70 万	100-220 万	250-450 万	中	P0
9. 工具调用与办公能力	30-80 万	120-300 万	350-700 万	中高	P2
10. 跨设备协同系统	40-100 万	150-350 万	400-900 万	高	P2
11. 安全、权限、沙箱、审计	30-80 万	120-300 万	350-800 万	高	P1/P2
12. 持久化、运维、监控	30-80 万	100-250 万	300-700 万	中	P1
13. 测试、评测与质量体系	25-60 万	100-240 万	300-600 万	中高	P0/P1
14. 高级数字人 / 动作生成预研	30-100 万	150-500 万	500-1500 万	高	P3
15. 美术资产与角色内容	50-200 万	200-800 万	800-2000 万	高	P1/P3

重要判断：如果只做技术 Demo，预算可压缩到 100-200 万；如果要实现文档中的全部平台目标，建议按 800-1800 万区间规划；如果追求高品质数字人、完整多端产品和商业化运营，预算可能进入 2000 万以上。

4. 分模块详细预算评估

4.1 产品设计与项目管理

模块范围

- 产品路线图；
- MVP / Beta / 正式版范围管理；
- 需求文档、PRD、技术验收标准；
- 用户体验流程；
- 团队排期、风险管理、周报、里程碑管理；
- 跨 AI、后端、Unity、美术、测试协作。

预算评估

档位	预算	周期	人员
基础档	20-40 万	2-3 个月	1 名产品/项目负责人
产品档	60-120 万	6-9 个月	产品负责人 + 项目经理/助理
增强档	150-250 万	12-18 个月	产品负责人 + 项目经理 + 体验策划

开源/现成可用

- Notion / 飞书 / Obsidian；
- GitHub Projects / Linear / Jira；
- ChatGPT / Codex / ClaudeCode 辅助文档和拆任务。

需要自研/沉淀

- 项目专属 AI 协作协议；
- 角色体验验收标准；
- 人格稳定性测试标准；
- 记忆质量评分标准；
- 跨设备体验流程。

4.2 技术架构与基础工程

模块范围

- 总体技术架构；
- FastAPI / 后端服务；
- 数据库、Redis、MinIO、Docker Compose；
- API 规范；
- 基础鉴权；
- 项目工程结构；
- CI/CD 基础；
- 代码规范、日志规范、错误处理。

预算评估

档位	预算	周期	人员
基础档	35-70 万	1-2 个月	技术负责人 + 后端 1 名
产品档	100-180 万	3-6 个月	技术负责人 + 后端 2 名 + DevOps 兼职
增强档	250-400 万	9-15 个月	架构师 + 后端组 + DevOps

开源/现成可用

- FastAPI / Node.js / ASP.NET Core；
- PostgreSQL；
- Redis；
- MinIO；
- Docker / Docker Compose；
- Nginx / Caddy / Traefik；
- Alembic / Prisma / SQLAlchemy。

需要自研/沉淀

- 适合 AI 角色系统的领域模型；
- 用户、角色、设备、记忆、工具之间的数据边界；
- 统一错误处理与审计日志；
- 模块化单体到微服务的演进路径。

4.3 AI 对话编排与模型网关

模块范围

- LangGraph 对话状态机；
- LiteLLM 模型网关；

- 云端模型与本地模型路由；
- Prompt 组装；
- 意图识别与规划；
- 工具调度入口；
- 响应后处理；
- 模型调用日志、成本统计、fallback。

预算评估

档位	预算	周期	人员
基础档	50-100 万	2-3 个月	AI 后端 1-2 名
产品档	120-250 万	4-8 个月	AI 后端 2 名 + 架构师
增强档	300-500 万	9-15 个月	AI 后端 3 名 + 模型工程师

开源/现成可用

- LangGraph；
- LangChain；
- LiteLLM；
- OpenRouter；
- Ollama；
- vLLM；
- llama.cpp。

需要自研/沉淀

- 面向人格角色的 Prompt 组装器；
- 模型路由策略；
- 不同模型的输出一致性修正；
- 高风险输出拦截；
- 模型效果评测集；
- 低成本模型和高质量模型的分层调用策略。

4.4 人格系统 / OOC / 关系状态机

模块范围

- CharacterProfile 人格 Schema；
- 角色身份、语气、世界观、边界；
- OOC 检测与修正；
- 关系阶段：陌生、熟悉、朋友、亲密、暧昧、恋人等；
- 情绪状态：开心、害羞、失落、等待、生气、修复等；
- 关系状态对 Prompt、语气、动作、主动性的影响。

预算评估

档位	预算	周期	人员
基础档	40-90 万	2-3 个月	角色策划 + AI 后端
产品档	120-260 万	4-8 个月	角色策划 + AI 后端 + QA
增强档	300-600 万	9-18 个月	体验策划组 + AI 后端 + 测试组

开源/现成可用

- Hermes / SOUL.md 思路可参考;
- Prompt 模板系统;
- LLM-as-judge 评测思路;
- 一些聊天角色卡格式可参考。

需要自研/沉淀

- 完整 CharacterProfile Schema;
- OOC 诱导测试集;
- OOC 输出后处理器;
- 关系状态机;
- 情绪状态机;
- 人格回归测试;
- 角色一致性评估标准。

预算风险

这是项目最容易被低估的模块。技术上不难跑通，但体验上很难做好。角色“像不像一个人”主要取决于这里，而不是模型本身。

4.5 长期记忆系统

模块范围

- 用户画像;
- 短期记忆;
- 长期记忆;
- 记忆抽取;
- 记忆评分;
- 记忆向量化;
- 记忆检索与重排序;
- 记忆冲突合并;
- 记忆衰减与遗忘;
- 记忆来源追踪;
- 用户主动删除记忆。

预算评估

档位	预算	周期	人员
基础档	60-130 万	2-4 个月	记忆/数据工程师 + AI 后端
产品档	180-380 万	5-10 个月	记忆工程师 + AI 后端 + QA
增强档	450-800 万	12-18 个月	记忆系统组 + 数据工程 + QA

开源/现成可用

- Mem0;
- pgvector;
- Milvus;
- Pinecone;
- Neo4j;
- Redis;
- LangChain RAG / GraphRAG。

需要自研/沉淀

- 什么值得记的判断规则；
- 记忆污染防治；
- 记忆置信度；
- 记忆重要度；
- 记忆冲突合并；
- 记忆过期与衰减；
- 敏感记忆处理；
- 用户删除记忆后的彻底不召回；
- 记忆对人格与关系状态的影响。

预算风险

长期记忆是核心壁垒，不建议完全依赖现成记忆框架。开源框架能解决存储和检索，但不能自动解决“该不该记、怎么记、何时忘、如何避免污染”。

4.6 语音交互系统

模块范围

- 音频采集；
- VAD；
- ASR；
- 说话人识别/分离；
- TTS；
- 情绪语音；
- 流式语音；
- 用户打断；
- 延迟优化；
- 音频与动作同步。

预算评估

档位	预算	周期	人员
基础档	40-90 万	2-3 个月	语音工程师或 AI 后端兼任
产品档	120-280 万	4-8 个月	语音工程师 + Unity + 后端
增强档	350-700 万	9-18 个月	语音多模态组 + Unity + QA

开源/现成可用

- Whisper；
- Qwen-ASR；
- WhisperLiveKit；
- WebRTC VAD / Silero VAD；
- ChatTTS；
- VoxCPM；
- Fish Audio API；
- WebSocket / WebRTC。

需要自研/沉淀

- 低延迟音频链路；
- TTS 分句生成策略；
- 用户打断策略；

- 情绪标签到语音参数的映射;
- 语音播放和口型、表情、动作同步;
- 多端语音状态一致性。

4.7 Unity 角色表现系统

模块范围

- Unity 角色客户端;
- WebSocket 通信;
- 角色控制器;
- 表情控制;
- 口型同步;
- 动作状态机;
- 情绪驱动动画;
- 场景表现;
- 调试面板;
- 可扩展到 MR / 桌面宠物 / 移动端。

预算评估

档位	预算	周期	人员
基础档	60-150 万	3-5 个月	Unity 工程师 1 名 + 角色资产
产品档	200-500 万	6-12 个月	Unity 2 名 + 技术美术 + 后端
增强档	600-1200 万	12-24 个月	Unity 组 + 技术美术组 + 动画组

开源/现成可用

- Unity Animator;
- Timeline;
- BlendTree;
- WebSocket 客户端库;
- VRM / Live2D / Ready Player Me 等角色管线可参考;
- 口型同步插件或工具。

需要自研/沉淀

- 后端事件到 Unity 动作的协议;
- 情绪-表情-动作映射表;
- 动作优先级与打断规则;
- 角色待机行为;
- 语音、口型、表情、动作同步器;
- MR / PC / 移动端不同表现层适配。

预算风险

如果只是技术 Demo, 成本可控; 如果要高质量虚拟人角色、动作库、服装、表情、场景、MR 表现, 预算会快速上升。

4.8 Web 管理后台 / 调试台

模块范围

- 用户管理;

- 角色配置;
- Prompt 配置;
- 记忆查看、编辑、删除;
- 对话日志;
- 模型调用日志;
- 工具调用日志;
- 设备状态;
- OOC 测试;
- 人格评测面板。

预算评估

档位	预算	周期	人员
基础档	30-70 万	1-2 个月	前端 1 名 + 后端支持
产品档	100-220 万	3-6 个月	前端 1 名 + 后端 1 名
增强档	250-450 万	6-12 个月	前端 + 后端 + QA

开源/现成可用

- React / Vue / Next.js;
- Ant Design / Arco Design / shadcn/ui;
- Supabase Studio 思路;
- Grafana 部分面板。

需要自研/沉淀

- 角色人格配置页;
- 记忆管理页;
- OOC 测试面板;
- 关系状态调试器;
- 设备任务面板;
- 模型成本统计面板。

4.9 工具调用与办公能力

模块范围

- 工具注册;
- 工具权限;
- 搜索、计算、API 调用;
- 文件读取;
- 文档总结;
- 表格处理;
- 代码执行;
- 沙箱隔离;
- 用户确认;
- 工具调用审计。

预算评估

档位	预算	周期	人员
基础档	30-80 万	2-3 个月	AI 后端 1 名
产品档	120-300 万	4-8 个月	AI 后端 + 安全/DevOps + QA

档位	预算	周期	人员
增强档	350-700 万	9-18 个月	Agent 工具组 + 安全 + QA

开源/现成可用

- LangChain Tools;
- MCP;
- pandas / openpyxl;
- E2B;
- 文件解析库;
- Office Agent 类项目可参考。

需要自研/沉淀

- 工具白名单;
- 权限分级;
- 危险操作二次确认;
- 文件访问范围限制;
- 代码执行沙箱;
- 工具执行日志与回滚;
- 陪伴角色语气与工具结果的融合。

4.10 跨设备协同系统

模块范围

- 设备注册中心;
- 设备心跳;
- 设备在线状态;
- 用户-设备绑定;
- 设备占用;
- 跨设备任务协议;
- 任务下发、确认、失败、重试;
- 文件传输;
- Web / Unity / 移动端 / PC 桌面端状态同步。

预算评估

档位	预算	周期	人员
基础档	40-100 万	2-4 个月	后端 + Unity/前端支持
产品档	150-350 万	5-10 个月	后端 2 名 + 客户端 + QA
增强档	400-900 万	12-18 个月	跨设备小组 + DevOps + QA

开源/现成可用

- WebSocket;
- MQTT;
- NATS;
- RocketMQ;
- PostgreSQL 设备表;
- Redis 在线状态;
- Syncthing 可参考;
- MinIO / S3。

需要自研/沉淀

- 设备注册协议；
 - 设备心跳协议；
 - 设备占用与释放；
 - 跨设备任务协议；
 - 任务优先级；
 - 失败重试；
 - 断线恢复；
 - 多设备冲突处理；
 - 用户隐私与设备权限。
-

4.11 安全、权限、沙箱、审计

模块范围

- 用户权限；
- 管理员权限；
- 设备权限；
- API 鉴权；
- 工具执行权限；
- 文件访问权限；
- 代码沙箱；
- 审计日志；
- Prompt 注入防护；
- 用户数据删除与导出。

预算评估

档位	预算	周期	人员
基础档	30-80 万	1-3 个月	后端 + DevOps 兼职
产品档	120-300 万	4-8 个月	DevOps/安全 + 后端 + QA
增强档	350-800 万	9-18 个月	安全工程师 + 后端 + 测试

开源/现成可用

- JWT / OAuth；
- Open Policy Agent；
- 容器沙箱；
- E2B / OpenSandbox / CubeSandbox 类方案；
- LlamaFirewall / Prompt Injection 防护思路；
- 审计日志系统。

需要自研/沉淀

- 工具调用安全策略；
 - 用户确认机制；
 - Prompt 注入测试集；
 - 角色系统的信息边界；
 - 记忆读取权限；
 - 用户要求删除记忆后的链路清理；
 - 高风险动作拦截。
-

4.12 持久化、运维、监控

模块范围

- PostgreSQL / pgvector;
- Redis;
- MinIO;
- 日志;
- Prometheus + Grafana;
- Jaeger / LangSmith;
- 数据备份;
- 部署脚本;
- CI/CD;
- 告警;
- 多环境配置。

预算评估

档位	预算	周期	人员
基础档	30-80 万	1-2 个月	DevOps 兼职 + 后端
产品档	100-250 万	3-8 个月	DevOps 1 名 + 后端支持
增强档	300-700 万	9-18 个月	DevOps + 安全 + QA

开源/现成可用

- PostgreSQL;
- pgvector;
- Redis;
- MinIO;
- Docker / Kubernetes;
- Prometheus;
- Grafana;
- Loki;
- Jaeger;
- LangSmith。

需要自研/沉淀

- AI 对话质量指标;
- 模型调用成本指标;
- 记忆写入失败告警;
- 设备离线告警;
- 工具执行风险告警;
- 角色 OOC 率统计;
- 自动备份和恢复演练。

4.13 测试、评测与质量体系

模块范围

- API 测试;
- 前后端功能测试;
- Unity 客户端测试;
- 语音延迟测试;
- 记忆准确性测试;

- 人格一致性测试;
- OOC 诱导测试;
- 工具安全测试;
- 跨设备断连恢复测试;
- 回归测试集。

预算评估

档位	预算	周期	人员
基础档	25-60 万	2-3 个月	QA 1 名兼职/全职
产品档	100-240 万	6-10 个月	QA 1-2 名
增强档	300-600 万	12-18 个月	QA 小组 + 自动化测试

开源/现成可用

- pytest;
- Playwright;
- Postman / Apifox;
- Unity Test Framework;
- LLM-as-judge 评测;
- 自动化回归脚本。

需要自研/沉淀

- 人格一致性测试集;
- 记忆污染测试集;
- OOC 诱导测试集;
- 关系状态回归测试;
- 情绪动作同步验收标准;
- 跨设备异常测试脚本。

4.14 高级数字人 / 动作生成预研

模块范围

- 2D / 照片动作迁移;
- 3D 骨骼动作生成;
- 视频数字人;
- 局部动作驱动;
- AI 生成动作清洗;
- 动作重定向;
- Unity 动作库扩充;
- 多模态动作意图转译。

预算评估

档位	预算	周期	人员
基础预研	30-100 万	2-3 个月	多模态工程师 + Unity
产品预研	150-500 万	6-12 个月	算法 + Unity + 技术美术
深度研发	500-1500 万	12-24 个月	算法组 + 美术组 + Unity 组

开源/现成可用

- 通义万相动作相关能力；
- 腾讯混元 HY-Motion；
- Runway Characters；
- SoulX-LiveAct；
- LongCat-Video-Avatar；
- 动作重定向工具链。

需要自研/沉淀

- 动作数据清洗；
- 骨骼重定向；
- 动作质量筛选；
- 动作和角色状态机融合；
- AI 动作生成结果进入 Unity 生产管线；
- 动作与语音、表情、情绪同步。

预算风险

这一块不建议作为 MVP 核心。它适合做 Demo 亮点和后期壁垒，但如果一开始投入过重，会拖慢核心系统落地。

4.15 美术资产与角色内容

模块范围

- 角色原画；
- 3D 模型；
- 绑定；
- 表情 BlendShape；
- 动作库；
- 服装；
- 场景；
- UI；
- 动效；
- 声音风格；
- 角色台词库。

预算评估

档位	预算	适用场景
Demo 档	50-200 万	一个角色基础模型 + 基础动作 + 简单场景
产品档	200-800 万	高质量角色、表情、动作、服装、场景
商业高品质档	800-2000 万 +	可持续运营的虚拟 IP / 数字人资产体系

可用资源

- 现成模型资产；
- VRM / Live2D / 商业模型；
- 动作捕捉素材库；
- AI 原型图；
- 商业音色服务。

需要自研/定制

- 角色专属视觉设定;
- 角色专属动作语言;
- 情绪表情体系;
- 品牌化 UI;
- 角色声音风格;
- 角色陪伴台词风格库。

5. 阶段预算方案

5.1 阶段 0：技术验证期

目标

打通最小技术链路，证明项目可做。

周期

4-6 周。

团队

角色	人数
产品/项目负责人	1
技术负责人	1
AI 后端	1
Unity 工程师	1
角色体验策划	0.5

功能范围

- 文本输入;
- Agent 编排;
- 模型回复;
- 对话入库;
- 简单记忆抽取;
- TTS 播放;
- Unity 展示文本/播放音频;
- 基础架构和技术方案确认。

预算

项目	预算
人力	25-55 万
云服务/API	2-8 万
设备/工具	2-10 万
管理与缓冲	5-15 万
合计	35-90 万

5.2 阶段 1：MVP 版本

目标

实现“稳定人格 + 长期记忆 + 基础语音 + Unity 角色表现”。

周期

2-3 个月。

团队

角色	人数
产品/项目负责人	1
技术负责人	1
AI 后端	2
记忆/数据工程师	1
Unity 工程师	1
前端工程师	1
角色体验策划	1
QA	1

功能范围

- 用户系统;
- 角色人格系统;
- LangGraph 编排;
- LiteLLM 模型网关;
- PostgreSQL + pgvector;
- Redis;
- Celery 记忆沉淀;
- 基础 OOC;
- TTS 输出;
- Unity 基础表情/动作;
- Web 管理后台基础版。

预算

项目	预算
人力	120-240 万
云服务/API	10-40 万
美术/角色资产	30-120 万
设备/工具	5-20 万
测试与缓冲	20-60 万
合计	185-480 万

5.3 阶段 2：体验增强版

目标

从“能聊”升级到“像活着的角色”。

周期

3-4 个月。

团队

角色	人数
产品/项目负责人	1
技术负责人	1
AI 后端	2
记忆/数据工程师	1
Unity 工程师	2
语音/多模态工程师	1
前端工程师	1
角色体验策划	1
技术美术/动画	1
QA	1-2

功能范围

- ASR;
- VAD;
- 流式 TTS;
- 用户打断;
- 关系状态机;
- 情绪状态机;
- 口型同步;
- 表情动作联动;
- 记忆冲突合并;
- 记忆衰减;
- 主动问候;
- 工具调用基础版。

预算

项目	预算
人力	260-520 万
云服务/API	30-120 万
美术/动画/声音	100-400 万
设备/测试	20-80 万
安全与缓冲	50-150 万
合计	460-1270 万

5.4 阶段 3：平台能力版

目标

补齐跨设备协同、工具能力、安全、运维和可上线能力。

周期

3-5 个月。

团队

角色	人数
产品/项目负责人	1
技术负责人	1
AI 后端	3
记忆/数据工程师	1-2
Unity 工程师	2
前端工程师	1
语音/多模态工程师	1
DevOps / 安全	1
角色体验策划	1
QA	2
技术美术	1

功能范围

- 设备注册中心;
- 设备心跳;
- 设备占用;
- 跨设备任务协议;
- WebSocket / MQTT / NATS;
- 文件/代码/表格工具;
- 工具沙箱;
- 权限和审计;
- Prometheus + Grafana;
- Jaeger / LangSmith;
- 数据备份;
- 用户数据导出/删除。

预算

项目	预算
人力	350-800 万
云服务/API	50-200 万
安全/运维/监控	80-250 万
美术/客户端扩展	100-400 万
测试/设备/缓冲	100-300 万
合计	680-1950 万

5.5 阶段 4：高级数字生命版

目标

实现动作生成、数字人预研、知识图谱、本地模型和高级平台能力。

周期

4-8 个月。

团队

角色	人数
技术负责人	1
AI 后端	2-3
算法/模型工程师	1-2
Unity 工程师	2
技术美术/动画	2
记忆/数据工程师	1
产品/角色体验	2
QA	1-2

功能范围

- HY-Motion 等动作生成预研;
- 视频数字人预研;
- 动作清洗与重定向;
- Unity 动作库扩充;
- Neo4j 知识图谱;
- vLLM 本地模型部署;
- LoRA / PEFT 人格微调实验;
- 多角色系统;
- 高级记忆图谱。

预算

项目	预算
人力	400-1000 万
算法/算力/模型实验	100-600 万
美术/动作/数字人资产	300-1500 万
设备/测试/运维	100-400 万
风险缓冲	150-500 万
合计	1050-4000 万

6. 三种总预算路线

6.1 保守 MVP 路线

目标

先验证产品核心，不追求完整平台。

范围

- 文本对话;
- 人格;
- 长期记忆;
- 基础 OOC;
- 基础 TTS;
- Unity 简单角色端;
- Web 调试后台。

周期

3-4 个月。

团队

6-8 人。

预算

200-500 万。

适合场景

- 立项验证；
 - 融资 Demo；
 - 客户初步演示；
 - 内部技术验证。
-

6.2 推荐产品化路线

目标

做出可以小规模用户测试的完整 Beta 产品。

范围

- 稳定人格；
- 长期记忆；
- 关系状态；
- 语音输入输出；
- Unity 表情、口型、预设动作；
- 管理后台；
- 基础工具调用；
- 初版安全、日志、监控。

周期

6-9 个月。

团队

10-12 人。

预算

700-1500 万。

适合场景

- 小规模商业试点；
 - IP 数字生命 Demo；
 - MR / 线下体验店技术样板；
 - 对外路演。
-

6.3 完整平台路线

目标

实现技术文档里的全部目标，并具备后续商业化扩展能力。

范围

- 多端客户端;
- 完整 Agent 编排;
- 长期记忆;
- 人格/OOC/关系;
- 语音与动作;
- 工具调用;
- 跨设备协同;
- 运维监控;
- 安全审计;
- 数字人动作生成预研;
- 知识图谱和本地模型实验。

周期

12-18 个月。

团队

12-18 人。

预算

1800-4000 万。

适合场景

- 长期产品化;
 - 平台型业务;
 - 多角色 IP 运营;
 - 多终端、多场景落地;
 - 融资后正式研发。
-

7. 哪些钱不能省

7.1 不能省：技术负责人

没有强架构师，项目会变成各种 API 和 Demo 的拼贴，后期必然返工。

7.2 不能省：长期记忆系统

长期记忆是产品壁垒。简单 RAG 不等于陪伴类记忆。

7.3 不能省：人格/OOC/关系状态

这个模块决定角色是否像“一个稳定存在的人”。

7.4 不能省：Unity 表现基础

如果最终要做数字生命或虚拟陪伴，角色表现不能只停留在网页聊天框。

7.5 不能省：测试和管理后台

没有后台和测试集，就无法调人格、调记忆、查 OOC、查设备和工具调用问题。

8. 哪些钱可以后置

模块	后置原因
LoRA 人格微调	早期 Prompt + 记忆 + 状态机更有效
Neo4j 知识图谱	第一阶段 pgvector + PostgreSQL 足够
实时动作生成	预设动作库更稳定、更便宜
视频数字人	适合 Demo，不适合作为早期核心链路
Kubernetes	早期 Docker Compose 足够
多端全覆盖	先 Web + Unity，再移动端/PC/MR
完整办公 Agent	陪伴内核稳定后再扩展
端到端加密同步	有明确隐私和多设备文件同步需求后再做

9. 推荐资金投入顺序

第一优先级

- 1. 技术架构;
- 2. AI 对话编排;
- 3. 人格系统;
- 4. 长期记忆;
- 5. Web 管理后台;
- 6. 基础测试体系。

第二优先级

- 1. 语音系统;
- 2. Unity 角色表现;
- 3. 关系状态机;
- 4. OOC 评测;
- 5. 记忆质量优化。

第三优先级

- 1. 工具调用;
- 2. 跨设备协同;
- 3. 安全沙箱;
- 4. 运维监控;
- 5. 多端扩展。

第四优先级

- 1. 动作生成;
- 2. 视频数字人;
- 3. 知识图谱;
- 4. LoRA 微调;
- 5. 本地模型规模化部署。

10. 推荐团队与预算组合

10.1 第一批团队：MVP 8 人组

岗位	人数	预计月成本
产品/项目负责人	1	3-5 万
技术负责人	1	6-10 万
AI 后端	2	8-14 万
记忆/数据工程师	1	5-8 万
Unity 工程师	1	4-7 万
前端工程师	1	3-5 万
QA/测试	1	2-4 万
合计/月	8 人	31-53 万/月

建议周期

3 个月。

人力预算

93-159 万。

加上云服务、美术、API、设备、缓冲

总预算建议：200-500 万。

10.2 推荐团队：产品化 12 人组

岗位	人数	预计月成本
产品/项目负责人	1	3-5 万
技术负责人	1	7-10 万
AI 后端	2	10-16 万
记忆/数据工程师	1	6-9 万
Unity 工程师	2	10-16 万
语音/多模态工程师	1	6-10 万
前端工程师	1	4-6 万
DevOps/安全	1	5-8 万
QA	1	3-5 万
角色体验策划	1	3-6 万
合计/月	12 人	57-91 万/月

建议周期

6-9 个月。

人力预算

342-819 万。

加上云服务、美术、API、设备、缓冲

总预算建议：700-1500 万。

10.3 完整平台团队：16-18 人组

岗位	人数	预计月成本
产品负责人	1	4-6 万
项目经理	1	3-5 万
技术负责人	1	8-12 万
AI 后端	3	15-24 万
记忆/数据工程师	2	12-18 万
Unity 工程师	2	10-16 万
语音/多模态工程师	1-2	6-20 万
前端工程师	1	4-6 万
DevOps/安全	1	6-10 万
QA	2	6-10 万
角色体验策划/编剧	1-2	4-12 万
技术美术/动画	1-2	5-16 万
合计/月	16-18 人	83-155 万/月

建议周期

12-18 个月。

人力预算

996-2790 万。

加上云服务、美术、API、设备、缓冲

总预算建议：1800-4000 万。

11. 风险预算

建议额外预留总预算的 15%-30% 作为风险预算。

风险	可能增加的成本
记忆效果不稳定，需要反复重构	+10%-20%
角色 OOC 严重，需要建立评测体系	+5%-15%
语音延迟不达标，需要换方案	+5%-20%
Unity 表现效果不满意，需要增加美术和动画	+20%-50%
跨设备协同复杂度超预期	+10%-30%
模型 API 成本超预期	+10%-40%
安全和工具沙箱返工	+10%-25%
高级数字人效果不稳定	+30%-100%

12. 最终预算建议

如果你现在还在技术可行性阶段

建议先申请：100-200 万验证预算。

用途：

- 核心技术链路验证；

- 对话 + 记忆 + 人格 Demo;
- Unity 角色端初版;
- 语音链路验证;
- 技术风险清单。

如果要做可演示 MVP

建议申请：200-500 万 MVP 预算。

用途：

- 8 人左右团队;
- 3 个月;
- 做出能给客户/投资人看的完整 Demo。

如果要做小规模产品化 Beta

建议申请：700-1500 万产品化预算。

用途：

- 10-12 人团队;
- 6-9 个月;
- 做出可小规模试点、可持续迭代的版本。

如果要完整实现文档所有目标

建议规划：1800-4000 万完整平台预算。

用途：

- 12-18 个月;
- 12-18 人团队;
- 完整覆盖长期记忆、人格、语音、动作、工具、跨设备、运维、安全、高级数字人预研。

13. 一句话结论

这个项目最合理的预算路径是：

先用 100-200 万做技术验证，再用 200-500 万做 MVP；如果 MVP 证明体验成立，再投入 700-1500 万做产品化 Beta；最终要完整实现文档中的全部技术目标，建议按 1800-4000 万规划。

真正应该优先投入的不是动作生成和数字人炫技，而是：

1. 稳定人格;
2. OOC 控制;
3. 长期记忆;
4. 关系状态;
5. 语音与 Unity 表现;
6. 管理后台和测试体系。

这些才是项目能不能成立的核心。