


陪伴类 AI 智能体 - 完整项目架构与技术选型文档

PDF 导出版：包含架构图视觉整理版、模块技术选型汇总、可行性对照表与阶段演进建议。

1. 完整项目架构图 (Mermaid)



注：上图为根据 Mermaid 架构代码整理的视觉版，用于 PDF 阅读与汇报展示。原始 Mermaid 源码保留在上传的 Markdown 文档中。

2. 各模块技术要点与推荐项目汇总

2.1 客户端层

技术点	推荐方案
前端斜杠拦截	原生事件监听 + .preventDefault()
跨设备通信 SDK	WebSocket + 本地消息总线 (自定义)
移动端框架	Flutter + memlocal_dart / React Native
3D 渲染	Unity / Unreal Engine / Three.js

2.2 接入网关层

技术点	推荐项目
API Gateway	Kong / Traefik / Envoy
会话缓存	Redis + LangGraph Checkpointer
设备心跳	WebSocket + 自研状态服务

2.3 控制与编排层

技术点	推荐项目
核心调度器	LangGraph (状态机编排)
多智能体协作	CrewAI / AutoGen
工具集成	LangChain + MCP 协议
办公能力工具	文件系统沙箱 + pandas/openpyxl + E2B 代码沙箱
跨设备编排	自研原子库 + 设备优先级决策

2.4 语音与动作协同层

子模块	推荐项目
ASR 引擎	Whisper / Qwen3-ASR / VibeVoice-ASR
说话人分离	WhisperLiveKit / VibeVoice-ASR
TTS 引擎	Fish Audio S2 / ChatTTS / VoxCPM
2D 动作迁移	通义万相 wan2.2-animate-move
3D 骨骼动作	腾讯混元 HY-Motion 1.0
实时数字人	Runway Characters / SoulX-LiveAct
局部动作驱动	美团 LongCat-Video-Avatar

2.5 记忆系统层

记忆类型	推荐项目
用户画像 + 设备清单	Mem0 / GetProfile
向量数据库	pgvector / Milvus / Pinecone
知识图谱	Neo4j + LangChain GraphRAG
情感/关系指标	自研状态机
短期缓存	Redis

2.6 模型推理层

技术点	推荐项目
模型网关	LiteLLM / OpenRouter

技术点	推荐项目
本地部署	Ollama / vLLM / llama.cpp
人格微调	LoRA + PEFT
提示词管理	LangSmith / DSPy

2.7 跨设备协同层

技术点	推荐项目
设备注册中心	PostgreSQL 设备表 + Redis 在线状态
消息总线	RocketMQ / MQTT / NATS
端到端加密同步	Syncthing (P2P) / Storacha
文件传输	自研分片上传 + 云存储中转

2.8 异步记忆沉淀层

技术点	推荐项目
五阶段流水线	Celery + LLM 抽取 / Mem0
记忆衰减	定时任务 + LRU 策略

2.9 持久化与运维

技术点	推荐项目
主数据库	PostgreSQL (pgvector) / Aurora
对象存储	MinIO / AWS S3
监控	Prometheus + Grafana + Loki
链路追踪	LangSmith / Jaeger

3. 开源项目参考蓝图与架构模块可行性对照表

模块	当前可行性	开发建议与推荐方案 ([开源]: 开源项目 / [定制]: 定制开发)
客户端	[成熟] 成熟可行	框架: Flutter / React Native / Electron。 渲染: Unity / Unreal。 安全: 前端拦截 / 命令。
接入网关	[成熟] 成熟可行	API Gateway: Kong, Traefik。 缓存: Redis。
控制编排	[成熟] 成熟可行	核心: LangGraph。 多智能体: CrewAI。
长期记忆	[成熟] 成熟可行	画像: Mem0, GetProfile。 向量: pgvector, Milvus。 图谱: Neo4j。[定制]
语音交互	[成熟] 成熟可行	情感指标: 自研关系状态机。 ASR: Qwen3-ASR, Whisper。 TTS: Fish Audio S2, ChatTTS。[定制]
动作生成	[需验证] 需集成但可行	动作同步器: 事件驱动整合。 2D: 通义万相。 3D: 腾讯混元 HY-Motion。 实时数字人: SoulX-LiveAct + 自研拼接。
跨设备协同	[需验证] 需集成但可行	设备发现/状态: [定制] 自研心跳与设备清单。 加密传输: Syncthing, Storacha。[定制] 任务执行: 分布式队列。

模块	当前可行性	开发建议与推荐方案 ([开源]: 开源项目 / [定制]: 定制开发)
安全与防护	[需验证] 需集成但可行	AI 防御: Meta SecAlign, LlamaFirewall。 沙箱: OpenSandbox, CubeSandbox。 [定制] 执行隔离: 强制沙箱。
办公能力	[成熟] 成熟可行	框架: CrewAI, Office Agent。 [定制] 工具封装: 代码沙箱、文档解析、API 调用。
人设管理	[需验证] 需集成但可行	[定制] 人设 Schema: 参考 Hermes SOUL.md 或自研。 3D 人格: SoulForge 框架。
推理监控	[成熟] 成熟可行	应用指标: [定制] 自研埋点。 链路追踪: LangSmith, Prometheus + Jaeger。
底层基建	[成熟] 成熟可行	数据库: PostgreSQL, pgvector。 消息队列: RocketMQ, Kafka。 容器化: Docker, Kubernetes。

混合开发策略建议: 60% 开源 + 30% 集成 + 10% 自研（核心壁垒）。

分阶段演进:

- 阶段一 (MVP, 1-2 个月): 以 Hermes 为底座，实现记忆、对话、基础工具。
- 阶段二 (体验增强, 2-3 个月): 集成 ASR/TTS、动作生成、办公能力。
- 阶段三 (生态构建, 2-3 个月): 完善跨设备协同、安全防护、运维体系。 —