

项目落地时间与预算评估差异说明

基于技术选型文档与分模块预算文档的口径统一说明

适用对象：长期记忆型虚拟陪伴智能体 / 数字生命系统立项评估

输出用途：内部立项、预算复核、客户/老板沟通说明

整理方向：解释技术可行性调研与完整产品预算之间的差异来源

目录

- 1. 核心结论
- 2. 为什么原技术选型文档看起来更乐观
- 3. 为什么预算文档会明显放大
- 4. 差异最大的几个来源
- 5. 建议统一为四档评估口径
- 6. 对原时间评估的修正建议
- 7. 对外解释口径
- 8. 后续建议
- 9. 附录：最容易被低估的自研模块

一、核心结论

一句话结论

两个文档的时间与预算差异，并不是前后矛盾，而是评估口径不同：技术选型文档回答“能不能做、最快多久跑通”；预算文档回答“要做成完整可交付产品，需要多少人、多少时间、多少成本和风险缓冲”。

原技术选型文档本质是技术可行性调研，重点判断每个模块是否有成熟技术、是否有开源工程可复用、能否通过集成方式跑通。

分模块预算文档则按完整产品落地进行估算，默认要覆盖团队人力、模块联调、稳定性、产品体验、测试验收、部署运维、安全合规和后期高级能力。

因此，原文档偏向“Demo / MVP 最短路径”，预算文档偏向“商业化产品交付路径”。两者不是同一层级的估算，不能直接横向比较。

文档类型	核心问题	典型口径	结论特点
技术选型文档	这些模块能不能做？用什么技术做？	技术验证 / Demo 跑通	周期短、预算低、偏乐观
预算评估文档	做成完整产品需要多少资源？	团队交付 / 产品化落地	周期长、预算高、偏保守

二、为什么原技术选型文档看起来更乐观

原技术选型文档中，许多模块被标注为“成熟可行”或“需集成但可行”。这个判断从技术可行性角度是成立的，但它没有完整计算产品化过程中的隐性成本。

隐性成本	具体含义	为什么会拉长周期
模块联调成本	LangGraph、LiteLLM、Redis、pgvector、Unity、TTS、ASR、WebSocket 等系统需要稳定协作。	单模块可用不等于整体链路稳定。
产品化成本	Demo 能跑，不代表用户可连续使用。	需要异常处理、兜底、状态恢复和后台管理。

隐性成本	具体含义	为什么会拉长周期
稳定性成本	记忆不能乱写、角色不能 OOC、语音不能卡顿、设备不能误连。	AI 项目对体验连续性要求高。
体验打磨成本	语气、关系、表情、动作、主动性都要反复调。	难以一次性设计到位。
测试成本	不仅测接口，还要测人格、记忆、越界、幻觉和回归。	传统功能测试不够。
运维成本	日志、监控、备份、安全、权限、部署文档。	上线必需，但技术调研阶段容易忽略。
返工成本	早期记忆、人设、动作同步方案可能多次调整。	核心体验模块天然需要迭代。
管理成本	多人协作会产生评审、沟通、排期、合并和返工。	团队越大越明显。

判断

原技术选型文档给出的时间，更适理解解为“理论技术集成时间”或“Demo 跑通时间”，不应直接等同于完整产品交付周期。

三、为什么预算文档会明显放大

预算文档如果按分模块拆分，会把研发、联调、测试、部署、运维、安全和风险缓冲全部计入。你的原架构目标本身并不是单一聊天机器人，而是一套完整的长期记忆型虚拟陪伴智能体平台。

预算文档计入的模块	说明
客户端	Web、移动端、PC / Unity 角色端、音频采集与播放、前端渲染。
接入网关	API 网关、会话管理、Redis 缓存、WebSocket 心跳。
控制编排	LangGraph 调度、意图识别、工具调度、跨设备编排。
模型推理	LiteLLM、模型路由、云端 / 本地模型、响应后处理。
长期记忆	用户画像、向量检索、知识图谱候选、情感 / 关系指标。
异步沉淀	对话归档、记忆抽取、记忆更新、衰减清理。
语音动作	ASR、TTS、情绪语音、口型、表情、身体动作。
跨设备协同	设备注册、心跳、状态同步、任务下发、文件同步。
工具能力	搜索、计算、文件、代码、表格、API 调用。
安全运维	权限、沙箱、日志、监控、链路追踪、备份和部署。

核心差异

预算文档不是在估算“接几个开源项目跑起来”，而是在估算“把这套系统做成可维护、可测试、可部署、可演示、可交付的产品”。

四、差异最大的几个来源

1. “能跑通”和“能落地”不是一个等级

级别	做到什么程度	时间口径
Demo	调一个 TTS API，生成音频。	几天到 2 周
可用	稳定播放、缓存、分句、失败重试。	2-4 周
好用	流式 TTS、打断、情绪语音、低延迟。	1-3 个月
产品级	多端一致、日志、异常处理、成本控制。	3 个月以上

2. 开源可用不等于可以直接上线

LangGraph、LiteLLM、Mem0、pgvector、Milvus、Whisper、ChatTTS、Celery、Prometheus、Grafana、Jaeger 等开源项目只是“零件”。它们能减少底座建设成本，但不能直接替代人格系统、OOC 检测、记忆筛选、关系状态机、动作同步器和跨设备任务协议。

3. 动作生成和实时数字人会显著放大预算

如果把通义万相、HY-Motion、Runway / SoulX-LiveAct、LongCat-Video-Avatar 等能力从“候选技术”变成“必须落地模块”，成本会明显上升。原因是这类模块还需要骨骼适配、动作清洗、动画重定向、Unity Animator 融合、表情 / 口型同步、实时性优化和美术调试。

4. 团队版本会比单人版本现金成本高很多

单人版本可以用更长时间慢慢推进，现金支出相对低；团队版本可以缩短周期、提高完整度，但每个月都会产生产品、技术、后端、Unity、前端、语音、测试、DevOps、策划和美术等固定人力成本。

五、建议统一为四档评估口径

为了避免后续沟通中继续出现“为什么时间和预算差这么多”的问题，建议所有预算、排期、汇报材料都明确标注版本口径。

版本	目标	周期	团队规模	做什么	不做什么
A 技术验证版	证明技术链路能跑	1-2 个月	2-4 人	文本对话、基础记忆、TTS、Unity 简单展示	复杂 OOC、关系状态、跨设备、动作生成、完整运维
B MVP 内测版	可内部 / 客户演示	3-5 个月	5-8 人	稳定人格、长期记忆、基础语音、Unity 表情动作、后台	高级数字人、完整跨设备、复杂办公 Agent
C 产品 Beta 版	可小规模用户测试	6-9 个月	8-12 人	ASR / TTS、关系状态、OOC、工具调用、后台、日志、设备同步	大规模商业化、高级动作生成、本地模型集群

版本	目标	周期	团队规模	做什么	不做什么
D 完整终局版	实现技术文档全部目标	12-18 个月	12-20 人	多端、跨设备、记忆、语音动作、工具、安全、运维、数字人预研	无，作为完整平台规划

六、对原时间评估的修正建议

原技术选型文档口径	建议修正为	说明
MVP：1-2 个月	技术验证：1-2 个月	适合作为最短链路验证，不代表可内测产品。
体验增强：2-3 个月	MVP 内测：3-5 个月	需要补人格、记忆、语音、Unity 表现和后台。
生态构建：2-3 个月	Beta 产品：6-9 个月	跨设备、工具、安全、运维、测试会显著增加工作量。
未单独区分完整终局	完整终局：12-18 个月	覆盖动作生成、知识图谱、本地模型、多端平台化等高级目标。

修正后的统一结论

更适合当前立项使用的规划是：先按 3-5 个月做 MVP 内测版；再按 6-9 个月做 Beta 产品版；完整终局能力按 12-18 个月规划。预算也应按版本分档，而不是只报一个总数。

七、对外解释口径

建议在对老板、客户或投资人解释时使用下面这段话：

推荐话术

前一份技术选型文档评估的是项目的技术可行性和最短集成路径，因此时间偏向 Demo / MVP 口径；后一份预算文档评估的是完整产品落地，包括团队人力、模块联调、产品化、测试、运维、安全、风险缓冲和高级数字人能力，因此时间和预算明显放大。两者不矛盾，区别在于一个是“能不能做、最快多久跑通”，另一个是“要做成完整产品，需要多少资源”。

八、后续建议

- 所有预算材料都必须标注版本口径：技术验证版、MVP 内测版、Beta 产品版或完整终局版。
- 汇报时不要只报一个总预算，应同时给出“低配验证、中配 MVP、高配产品、完整平台”四档方案。
- 将动作生成、知识图谱、本地模型、LoRA、复杂跨设备协同列为后置或专项预研，避免第一阶段吞噬预算。
- 第一阶段优先验证稳定人格、长期记忆、基础语音和 Unity 角色表现，这是项目成立的核心。
- 预算文档中要明确哪些是开源集成成本，哪些是自研攻关成本，哪些是运维和测试成本。

● 建立统一的验收标准：Demo 跑通、MVP 可演示、Beta 可内测、终局可平台化，四者不能混用。

附录：最容易被低估的自研模块

自研模块	为什么容易被低估	对预算的影响
人格系统	不只是 Prompt，而是角色设定、语气、边界、关系阶段的组合。	需要长期调试和体验策划参与。
OOC 检测与修正	模型会出戏、泄露设定、越过关系边界，需要前后处理机制。	需要规则、模型评估和测试集。
记忆筛选与防污染	存储和检索可用开源，但“什么值得记”必须自研。	决定陪伴体验质量，返工风险高。
关系状态机	陪伴产品要有关系变化，而不是单纯聊天记录。	需要产品、算法和后端共同设计。
情绪-语音-动作同步	TTS、表情、口型、动作都要统一节奏。	Unity、语音、多模态、美术联调成本高。
跨设备任务协议	MQTT / WebSocket 只是通信工具，任务状态、占用、重试、权限要自研。	涉及后端、客户端、运维和测试。
工具安全与沙箱	一旦能操作文件、代码、表格，就必须做权限和审计。	影响上线安全和合规成本。

本说明文档基于已形成的技术选型文档、分模块预算文档及其评估差异解释整理，用于统一项目阶段、预算和排期口径。